预训练模型学习情况周报 7

姚凯

一、 本周学习:

项目实践

完成任务二：命名实体识别任务

数据集：CLUENER2020

方案：基于预训练模型 RoBERTa，改进自 BERT

1) 数据预处理

将原始标签转换为 BIOS 标注:

{"text": "彭小军认为，国内银行现在走的是台湾的发卡模式，先通过跑马圈地再在圈的地里面选择客户，", "label": {"address": {"台湾": [[15, 16]]}, "name": {"彭小军": [[0, 2]]}}}

['B-name', 'I-name', 'I-name', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-address', 'I-address', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O']

2) 构建数据集

第一步得到文本和标签序列，分别通过自建词表转为索引序列，并将每个 batch 中的句子和标签补全到同一长度。数据集按 9：1 序列分割为训练集和验证集

3) 模型结构

使用的预训练模型为中文 RoBERTa-wwm-ext-large，解决序列元素的多分类问题，条件随机场 CRF 则精细标签之间的依赖关系

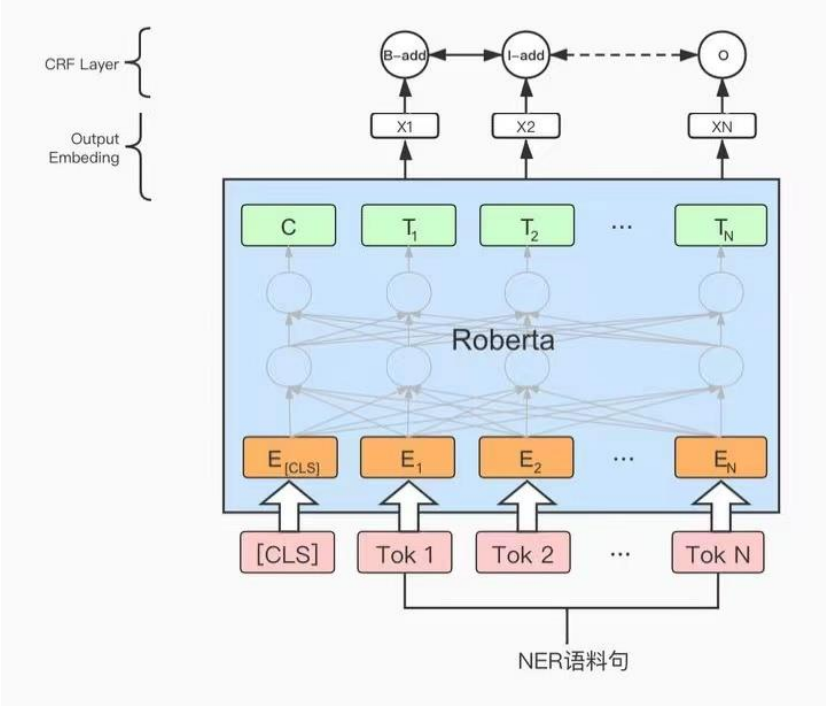

整个模型将处理好的文本序列（索引格式）输入 Roberta 中，得到预测标签，再输入到 CRF 中修改预测标签，经过词表映射，与真实标签计算评测分数，来微调模型 weights

训练结果

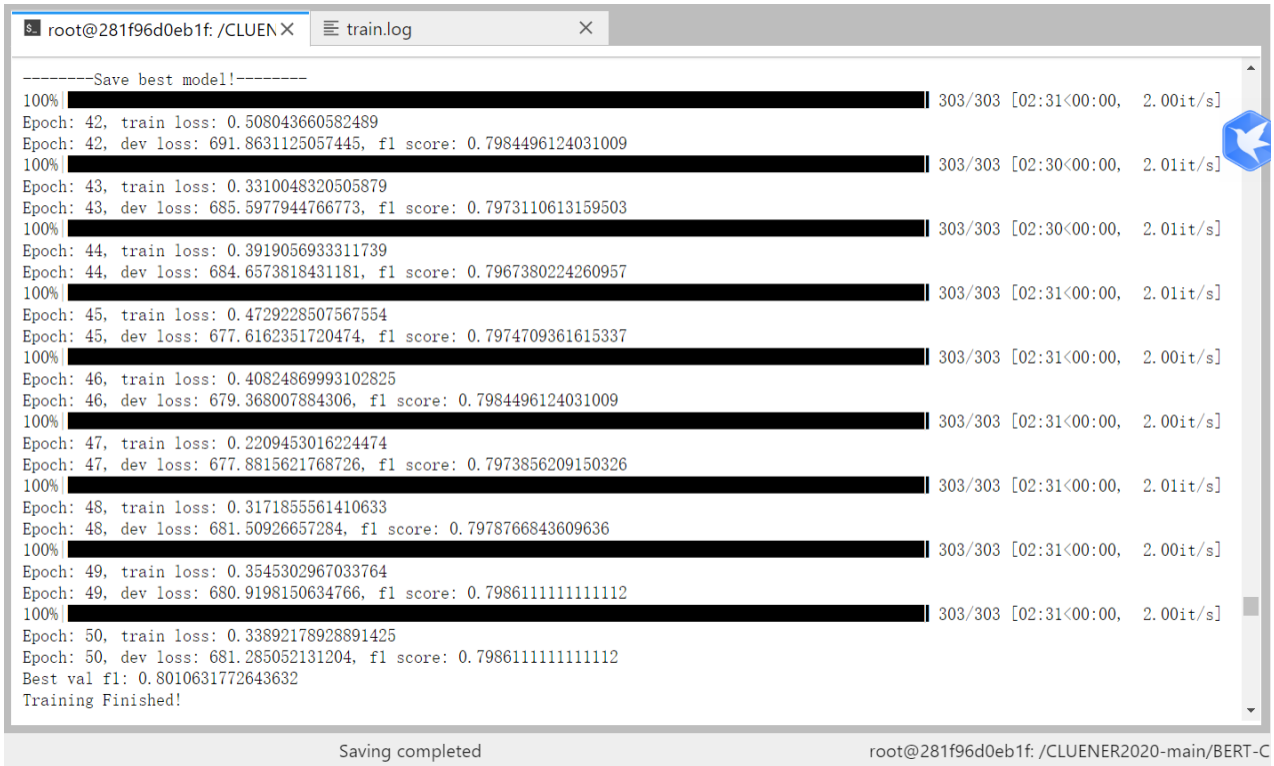

参考：

https://blog.csdn.net/weixin_44388679/article/details/106871992

https://zhuanlan.zhihu.com/p/346828049

https://github.com/hemingkx/CLUENER2020

调试 bug：

If reserved memory is >> allocated memory try setting max_split_size_mb to avoid fragmentation.
解决：增大内存，或者逐步减半 batch_size

论文阅读

继续看完了《Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Process》这篇论文

对比

预训练+微调（pre-train+Fine tune）：一个具有固定架构的模型通过预训练作为语言模型，当应用到下游任务时，引入额外参数，使用针对具体任务的目标函数微调模型参数。需要精心设计预训练和微调阶段使用的训练目标。

预训练+提示+预测（pre-train,prompt,predict）:选择适当的 prompt 方法用预训练后的语言模型本身即可完成所需的预测，甚至无需额外的特定任务训练。

提示学习步骤

a) 设计一个 prompt 映射函数（即模板 template），把原始文本 x 转变为基于 prompt 的模型需要的格式 x'。文本 x"I love this movie."，其转变之后的文本 x'为"[x]. Overall it was a [Z] movie."。[Z]代表需要预测的答案文本 z。

b) 输入 x'，在合适的语言模型上寻得具有最大概率的[z]

c) 构造 Prompt 答案空间映射（Verbalizer），对应预测的 Z 与实际需要的标签

y。并通过映射得到所需的预测标签 y。

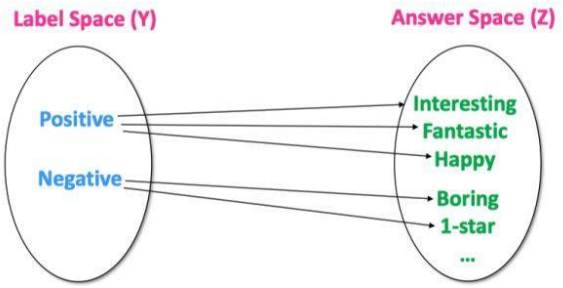

Prompt 设计：

1) 手工设计，基于人类实验、经验和语言专业知识

2) 自动学习模板：

A. 离散 prompts：自动生成由自然语言的词组成的 prompt，其搜索空间是离散的。

B. 连续 Prompts：生成的 prompt 只用机器理解，直接作用在模型的向量空间

Answer 设计：

根据任务选择答案[Z]的形状（字符/一句话/一篇文章），在答案空间搜索以及到目标 Y 的映射也有手工设计和自动设计两种。

参考：

https://blog.csdn.net/qq_42393368/article/details/121229804