预训练模型学习情况周报 12 姚凯

一、 本周学习:

知识表示实践

数据集 WN18RR 结构:

实体集合, 关系集合, 测试集, 训练集, 验证集

train2id.txt	2021-04-06 1:24	文本文档	1,099 KB
entity2id.txt	2021-04-06 1:24	文本文档	629 KB
type_constrain.txt	2021-04-06 1:24	文本文档	604 KB
test2id_all.txt	2021-04-06 1:24	文本文档	47 KB
test2id.txt	2021-04-06 1:24	文本文档	40 KB
valid2id.txt	2021-04-06 1:24	文本文档	39 KB
relation2id.txt	2021-04-06 1:24	文本文档	1 KB
N. 对 文件			

N对n文件用于 filter 等操作

n-1.txt	2021-04-06 1:24	文本文档	19 KB
n-n.txt	2021-04-06 1:24	文本文档	15 KB
1-n.txt	2021-04-06 1:24	文本文档	7 KB
n-n.py	2021-04-06 1:24	JetBrains PyChar	4 KB
1-1.txt	2021-04-06 1:24	文本文档	1 KB

链接预测任务: 三元组<e1, h, e2>知道任意两个, 预测剩下那个, l, r 分别指预测(空缺部分)为头实体还是尾实体

训练中,随机挑选三元组,去掉头实体和尾实体,用其他三元组对应项代替,即为反例。<h,l,t>,<h',l,t'>

实验指标

Hit@N: 缺失实体的三元组遍历实体文件的所有实体并打分排序,取前 N 个结果,需要预测的三元组个数为 K, 所有预测结果中正确结果在前 N 个结果的个数为 kj 个

$$Hits@N = \frac{K_j}{K}$$

MRR: Ri 是每个预测正确结果排序名次

$$rank_j = \frac{1}{R_j}$$

$$MRR = \frac{1}{K} \sum_{j=1}^{K} rank_j$$

MR: 评估整体排序质量的指标

$$MR = \frac{1}{K} \sum_{j=1}^{K} R_j$$

模型更新的是所有 entities 和 relations 的 Embedding 数据,每一次 SGD 更新的参数就是一个 Batch 中所有 embedding 的值

测试环节的 Filter&raw: 图谱中存在 1 对 N 的情况(<e1,r,e2>,<e1,r,e3>),在测试遍历所有实体排序时,可能新组成的 triple 在训练集中,故打分更高。这种情况将这个 triple 从测试中过滤掉,从而得到 Filter 测试结果。

transE

```
(pytorch1120) kyle@kyle_virtual-machine:~/Lab/SEU/OpenKE$ python my_transE.py
Input Files Path : ./benchmarks/Whi8RR/
The toolkit is importing datasets.
The total of relations is 11.
The total of frain triples is 86835.
Input Files Path : ./benchmarks/Whi8RR/
The total of train triples is 86835.
Input Files Path : ./benchmarks/Whi8RR/
The total of valid triples is 3034.
Finish initializing...
Epoch 999 | loss: 0.102426: 100%|
100%|
100%|
1000/1000 [2:28:54<00:00, 8.93s/it]
1000/100
```

TransH

```
(pytorch1120) kylegkyle-virtual-machine:-/Lab/SEU/OpenKE$ python my_transH.py
Input Files Path : ./benchmarks/WN18RR/
The total of relations is 11.
The total of relations is 11.
The total of frain triples is 86835.
Input Files Path : ./benchmarks/WN18RR/
The total of train triples is 3034.
Finish initializing...
Epoch 999 | loss: 0.030988: 100%|
| 1000/1000 [3:45:21<00:00, 13.52s/it] |
| 1000/1000 [3:45
```

实验结果 transE 的 hit@10 为 47.7%,transH 的 hit@10 为 45.0%,MR 的值都略高,参数(loss 中的 λ ,学习率)还需优化

理论上 transH 可以表示一对 N, hit@10 应该更高, 原 paper 中的结果也是 transE 的更高一点,应该是 transH 参数要再优化(?)

Model	WN18RR	FB15K237	WN18RR (Paper*)	FB15K237 (Paper*)
TransE	0.512	0.476	0.501	0.486
TransH	0.507	0.490	-	-

参考:

https://zhuanlan.zhihu.com/p/508508180

https://zhuanlan.zhihu.com/p/152257102